



ΔΗΜΟΚΡΙΤΕΙΟ
ΠΑΝΕΠΙΣΤΗΜΙΟ
ΘΡΑΚΗΣ

ΤΜΗΜΑ
ΗΜ & ΜΥ

Αναγνώριση Προτύπων

2023-2024

ΗΩ04 - Εργασία 4

Ονοματεπώνυμο: Δημήτριος Αναστασούδης
ΑΕΜ: 58085

Άσκηση 1.

1.

Το [IRIS data set](#) περιέχει μορφολογικές μετρήσεις για 150 φυτά iris (είδος κρίνου, αγριόκρino). Τα δεδομένα είναι της μορφής: (μήκος σέπαλου, πλάτος σέπαλου, μήκος πετάλου, πλάτος πετάλου) σε cm. Από αυτά τα 150 φυτά, 50 είναι Iris Setosa (ω_1), 50 είναι Iris Versicolour (ω_2) και 50 είναι Iris Virginica (ω_3).

α)

A. Να χωριστεί το dataset σε 80% training και 20% test δείγματα με τυχαίο τρόπο.

Ο κώδικας υπάρχει στο αρχείο AP_HW04_1_58085.ipynb και έγινε με την συνάρτηση `train_test_split` της βιβλιοθήκης `sklearn.model_selection`.

β)

B. Να εκπαιδευτεί νευρωνικό δίκτυο 2 επιπέδων για την ταξινόμηση των δειγμάτων, όπου το 1^ο layer θα έχει 30 νευρώνες και συνάρτηση ενεργοποίησης θα είναι `sigmoid`.

Ο κώδικας υπάρχει στο αρχείο AP_HW04_1_58085.ipynb.

Το output του κώδικα που παίρνουμε είναι το εξής:

```
Η ακρίβεια του μοντέλου στο σετ εκπαίδευσης: 0.98
Η ακρίβεια του μοντέλου στο σετ δοκιμής: 0.97
```

γ)

Γ. Να αποτυπωθεί η εξέλιξη του test accuracy μετά από κάθε epoch εκπαίδευσης σε διάγραμμα, και να υπολογιστεί ο πίνακας σύγχυσης του τελικού μοντέλου για το test set.

Ο κώδικας υπάρχει στο αρχείο AP_HW04_1_58085.ipynb.

Το output του κώδικα που παίρνουμε είναι το εξής:


Η ακρίβεια του μοντέλου στο σετ εκπαίδευσης: 0.99

Η ακρίβεια του μοντέλου στο σετ δοκιμής: 0.97

Πίνακας Σύγχυσης:

```
[[ 7  0  0]
 [ 0 13  0]
 [ 0  1  9]]
```

Το διάγραμμα που παίρνουμε φαίνεται παρακάτω:



δ)

Δ. Να επαναληφθεί η εκπαίδευση με συνάρτηση ενεργοποίησης την ReLu. Τί παρατηρείτε?

Το output που παίρνουμε είναι το εξής:


Η ακρίβεια του μοντέλου στο σετ εκπαίδευσης: 0.97

Η ακρίβεια του μοντέλου στο σετ δοκιμής: 0.97

Πίνακας Σύγχυσης:

```
[[13  0  0]
 [ 0  5  0]
 [ 0  1 11]]
```

Το διάγραμμα που παίρνουμε φαίνεται παρακάτω:



Παρατηρούμε ότι με την χρήση της ReLU το μοντέλο συγκλίνει γρηγορότερα. Επίσης παρατηρούμε ότι η ακρίβεια, αν και είναι αρκετά παρόμοια, στην πρώτη περίπτωση ήταν λίγο μεγαλύτερη. Τέλος, βλέπουμε ότι στο πρώτο διάγραμμα η ακρίβεια μετά από έναν συγκεκριμένο αριθμό Epochs είναι πιο σταθερή από το διάγραμμα της ReLU.

ε)

- Ε. Πειραματιστείτε με τις παραμέτρους σχεδίασης, και προτείνετε ένα δίκτυο που επιτυγχάνει καλύτερη ακρίβεια από τα προηγούμενα. Τεκμηριώστε το αποτέλεσμα με τα απαραίτητα γραφήματα και πίνακες σύγκρισης.


Στο ερώτημα αυτό, ο πειραματισμός έγινε στους παραμέτρους σχεδίασης, όπως τον αριθμό και το μέγεθος των επιπέδων, τις συναρτήσεις ενεργοποίησης, το ρυθμό εκμάθησης, την τεχνική βελτιστοποίησης, τον αριθμό των εποχών, και την χρήση τεχνικών όπως dropout για την αποφυγή της υπερπροσαρμογής.

Συγκεκριμένα, υπήρξε αύξηση στους νευρώνες, ενεργοποίηση Regulator, αλλαγή στο learning rate, αλλά και προσθήκη ενός Warm Start.

Τρέχοντας τον κώδικα το output που παίρνουμε είναι το εξής:

```
Ακρίβεια εκπαίδευσης: 0.97
Ακρίβεια δοκιμής: 1.00
Πίνακας Σύγχυσης:
[[10  0  0]
 [ 0  9  0]
 [ 0  0 11]]
```

Επιπλέον, τα ζητούμενα διαγράμματα που παίρνουμε, φαίνονται παρακάτω:




Όπως παρατηρούμε, οι αλλαγές φαίνεται ότι βοήθησαν στην βελτιστοποίηση της απόδοσης. Επιπλέον, παρατηρείται ότι σταθεροποιείται η ακρίβεια στο σετ δοκιμής και ότι η απώλεια μειώνεται σταθερά.

στ)

ΣΤ. Στο καλύτερο δίκτυο από αυτά που εκπαιδεύσατε, υπολογίστε και αποτυπώστε τις καμπύλες precision-recall για τις τρεις κλάσεις, μεταβάλλοντας το κατώφλι της πιθανότητας κάθε κλάσης. Ποια κλάση είναι πιο εύκολα διαχωρίσιμη με βάση το AUC (Area Under Curve) που προκύπτει από τις καμπύλες;

Το output που παίρνουμε από τον κώδικα είναι ότι η κλάση με το υψηλότερο AUC είναι η Κλάση 2.

Επίσης, παρακάτω μπορείτε να δείτε το διάγραμμα:



Άσκηση 2.

2.

Να εκπαιδεύσετε ένα νευρωνικό δίκτυο με αρχιτεκτονική autoencoder, με 3 επίπεδα κωδικοποίησης 128, 32 και 3 νευρώνων και 3 αντίστοιχα επίπεδα αποκωδικοποίησης, χρησιμοποιώντας το training set της βάσης δεδομένων MNIST Digits που χρησιμοποιήθηκε στην εργαστηριακή άσκηση 6.

α)

- A. Ποια αρχιτεκτονική autoencoder πέτυχε το μικρότερο μέσο τετραγωνικό σφάλμα στα δεδομένα εκπαίδευσης? Αυτή που χρησιμοποιήθηκε στην εργαστηριακή άσκηση ή αυτή που εκπαιδεύσατε? Γιατί πιστεύετε ότι συνέβη αυτό?

Τρέχοντας τον κατάλληλο κώδικα που ζητείται, παίρνουμε τα εξής αποτελέσματα:

- Στη δική μας εκπαίδευση:

```
Epoch 1, Loss: 0.04105505347251892
Epoch 2, Loss: 0.03959324583411217
Epoch 3, Loss: 0.036715466529130936
Epoch 4, Loss: 0.038657158613204956
Epoch 5, Loss: 0.034704819321632385
Epoch 6, Loss: 0.04097607359290123
Epoch 7, Loss: 0.03772496432065964
Epoch 8, Loss: 0.03420143574476242
Epoch 9, Loss: 0.03046075627207756
Epoch 10, Loss: 0.029134215787053108
Epoch 11, Loss: 0.03295297548174858
Epoch 12, Loss: 0.03485935181379318
Epoch 13, Loss: 0.03761591762304306
Epoch 14, Loss: 0.032083477824926376
Epoch 15, Loss: 0.03352269530296326
Epoch 16, Loss: 0.035188328474760056
Epoch 17, Loss: 0.030887817963957787
Epoch 18, Loss: 0.030165797099471092
Epoch 19, Loss: 0.03614851459860802
Epoch 20, Loss: 0.029390987008810043
```

- Στην εκπαίδευση στην εργαστηριακή άσκηση:



```
Epoch [1/20], Loss: 0.0216
Epoch [2/20], Loss: 0.0148
Epoch [3/20], Loss: 0.0093
Epoch [4/20], Loss: 0.0097
Epoch [5/20], Loss: 0.0096
Epoch [6/20], Loss: 0.0074
Epoch [7/20], Loss: 0.0092
Epoch [8/20], Loss: 0.0081
Epoch [9/20], Loss: 0.0069
Epoch [10/20], Loss: 0.0079
Epoch [11/20], Loss: 0.0071
Epoch [12/20], Loss: 0.0063
Epoch [13/20], Loss: 0.0060
Epoch [14/20], Loss: 0.0064
Epoch [15/20], Loss: 0.0060
Epoch [16/20], Loss: 0.0079
Epoch [17/20], Loss: 0.0049
Epoch [18/20], Loss: 0.0071
Epoch [19/20], Loss: 0.0067
Epoch [20/20], Loss: 0.0061
```


Όπως είναι και προφανές, το λιγότερο μέσο τετραγωνικό σφάλμα, ή MSE είναι μικρότερο στην εργαστηριακή άσκηση. Συγκεκριμένα, εκεί είναι περίπου 0.008 ενώ στην δική μας περίπτωση περίπου 0.03.

Η διαφορά στο MSE μπορεί να προκύπτει από τους παραμέτρους εκπαίδευσης που ορίστηκαν, στην αρχιτεκτονική αλλά και στη διαδικασία εκπαίδευσης.

β)

- B. Να απεικονίσετε κατάλληλα το σύνολο των εικόνων του training set όπως κωδικοποιούνται στο latent space, με κατάλληλο χρώμα που να αντιστοιχεί στο label καθεμιάς. Κάνετε το ίδιο και για τις εικόνες του test set. Διατηρούνται τα χαρακτηριστικά της κατανομής των απεικονίσεων και στα δύο σύνολα? Σχολιάστε.

Τρέχοντας τον κατάλληλο κώδικα που ζητείται, το output που παίρνουμε είναι τα εξής διαγράμματα:




Από ότι βλέπουμε, τα χαρακτηριστικά της κατανομής των απεικονίσεων διατηρούνται σε κάποιο βαθμό και στα δύο σύνολα. Οι συστάδες είναι ορατές και στα δύο γραφήματα, αλλά παρατηρούμε ότι κάποιες συστάδες ενώνονται ή επικαλύπτονται μεταξύ τους. Ένας λόγος που συμβαίνει αυτό είναι λόγω της συμπίεσης της πολυδιάστατης πληροφορίας σε δύο διαστάσεις.

γ)

- Γ. Να χρησιμοποιήσετε τον κλάδο αποκωδικοποίησης του εκπαιδευμένου autoencoder ώστε να δημιουργήσετε εικόνες ξεκινώντας από τυχαία σημεία του latent space. Εξερευνήστε το latent space δοκιμάζοντας διάφορα σημεία του χώρου και παρατηρώντας τις εικόνες που παράγονται. Αντιστοιχούν όλες οι περιοχές του latent space σε πραγματικά ψηφία? Σχολιάστε τα ευρήματά σας παραθέτοντας παραδείγματα εικόνων.

Τρέχοντας τον κατάλληλο κώδικα για την απάντηση του ζητούμενου, παίρνουμε το παρακάτω output:



Φαίνεται ότι δεν είναι πουθενά φανερό αν επιδεικνύονται πραγματικά ψηφία. Πράγμα που σημαίνει ότι είτε το μοντέλο δεν έχει λάβει την κατάλληλη εκπαίδευση είτε τα τυχαία σημεία που επιλέγουμε, πρέπει να επιλεγθούν πιο κατάλληλα.

Άσκηση 3.

3.

Το [Breast Cancer Wisconsin](#) είναι ένα σύνολο δεδομένων που περιέχει 30 μορφολογικά χαρακτηριστικά των καρκινικών κυττάρων από 569 βιοψίες μαστού, καθώς και το είδος του όγκου για κάθε δείγμα (κακοήθης: κλάση 1 ή M | καλοήθης: κλάση 0 ή B).

α)

A. Να χωριστεί το dataset σε 70% training και 30% test δείγματα με τυχαίο τρόπο.

Μπορείτε να βρείτε τον ζητούμενο κώδικα στο αρχείο AP_HW04_3_58085.ipynb.

Το output που παίρνουμε αναφορικά με τις διαστάσεις είναι το εξής:

```
Training set dimensions: (398, 30)
Test set dimensions: (171, 30)
```

β)

B. Να μετατρέψετε το 10% των training δεδομένων σε missing values με τυχαία ομοιόμορφη κατανομή, και να εκπαιδεύσετε έναν δένδρικό ταξινομητή (tree classifier) με μέγιστο βάθος 5 επίπεδα. Υπολογίστε την ακρίβεια πρόβλεψης του ταξινομητή στο test set.

Τρέχοντας τον κώδικα που απαντάει στο ζητούμενο του ερωτήματος, παίρνουμε το παρακάτω output, αναφορικά με το Accuracy:

```
Accuracy: 0.9590643274853801
```

γ)

Γ. Με τα ίδια training και test sets να εκπαιδεύσετε ένα random forest¹ (RF) με 100 ταξινομητές μέγιστου βάθους 3, χρησιμοποιώντας 5 features ανά δένδρο χωρίς bootstrapping των training δεδομένων. Να υπολογίσετε την ακρίβεια πρόβλεψης του RF στο test set.

δ)

- Δ. Υπολογίστε το feature importance για τον δένδρικό ταξινομητή και το RF. Σχολιάστε τα μέχρι τώρα αποτελέσματα και τις διαφορές που παρατηρείτε.

ε)

- Ε. Να εκπαιδεύσετε το ίδιο RF για μεταβλητό ποσοστό missing values (0% έως 80% ανά 10%) και για κάθε forest να υπολογίσετε το classification accuracy εισάγοντας στο test set μεταβλητό ποσοστό missing values (0% έως 80% ανά 10%). Απεικονίστε κατάλληλα τη συνολική συμπεριφορά της ακρίβειας του RF ταξινομητή σε σχέση με το ποσοστό missing values. Σχολιάστε την αντοχή του random forest στα missing data, τόσο στο training όσο και στο testing. Σε ποιο από τα δύο είδη missing data είναι περισσότερο ευαίσθητος?

στ)

- ΣΤ. Να εκπαιδεύσετε έναν δένδρικό ταξινομητή και έναν RF ταξινομητή όπως στα προηγούμενα, για 10% missing data στο training set. Υπολογίστε τις καμπύλες precision-recall για τους δύο ταξινομητές² (χωρίς missing data στο test set). Ποιος ταξινομητής έχει καλύτερη συμπεριφορά και γιατί? Δεδομένου ότι οι ταξινομητές που εκπαιδεύσατε αποτελούν συστήματα πρόβλεψης της κακοήθειας όγκων, ποια χαρακτηριστικά της καμπύλης έχουν περισσότερη βαρύτητα κατά την πρακτική εφαρμογή?